

Relações causais no contexto da saúde mental

Causalidade em Aprendizado de Máquina

Prof. Dr. Anísio Mendes Lacerda

Cristiane Freitas

Felipe Cador

Gabriel Diniz

Thamara Dias

Belo Horizonte, 2022

Cronograma

- 1 Descrição do problema
- 2 Objetivo
- 3 Metodologia
- 4 Resultados
- 5 Conclusões

Problemática : Suicídio



- Importante problema de saúde pública
- Está entre as 20 causas de morte mais comuns, superando malária, câncer de mama ou homicídio
- Houve um aumento de 24% dos casos nos últimos 20 anos
- Ocorre um suicídio a cada 40 segundos no mundo
- + 700 mil pessoas morrem por suicídio anualmente
- Piorou com a pandemia da COVID-19

Aprendizado de máquina - Saúde mental

Predição de ideação suicida : arquiteturas neurais que extraem padrões de dados em grande escala




Problema : não fazem distinção entre causas, efeitos e fatores de confusão (puramente **correlativos**)

Importância da Causalidade

- O conhecimento da relação causal entre os dados observados e *features* pode ser usado para formalizar correlações espúrias
- Na saúde mental, focar nos indivíduos e fundamental
- Responder questões do tipo : O que acontecerá se uma pessoa com ideação suicida deixar de ingerir bebida alcoólica ?
- Carência de estudos que combinem causalidade com a utilização de dados clínicos de pacientes ambulatoriais

Objetivo

Utilizar dados de classificação clínica para identificar os possíveis fatores causais que possam estabelecer relações com a ideação suicida



Metodologia

- Dataset
- **Aprendizado Supervisionado Causal** : identificar os padrões existentes na predição de ideação suicida
 - Técnicas causais para selecionar as *features* (Markov Blanket)
 - Grafos causais :
 - isolar as correlações internas não-causais entre as *features*
 - identificar *features* com influência causal direta ao nosso objetivo de classificação
 - Modelos causais estruturais
 - Contrafactual
- Explicabilidade
- **Baseline** : Rede neural (2 layers)

Dataset

STAR*D

- Ensaio clínico, randomizado e multicamadas aplicado em pacientes ambulatoriais com transtorno depressivo
- Compara várias opções de tratamento para aqueles que não alcançaram uma resposta satisfatória com o medicamento Citalopram, um inibidor seletivo de recaptação de serotonina
- 4.000 adultos (idades entre 18 e 75 anos) sem características psicóticas
- Resultado primário de avaliação clínica : 17 itens da escala de classificação Hamiltoniana de depressão colhidos no início e fim de cada nível de tratamento através de entrevistas telefônicas
- Resultado secundário de avaliação clínica : sintomas depressivos autorrelatados, sintomas físicos e mentais, efeito colateral, satisfação do paciente e custo com cuidados com a saúde

Dataset

Target : Suicídio

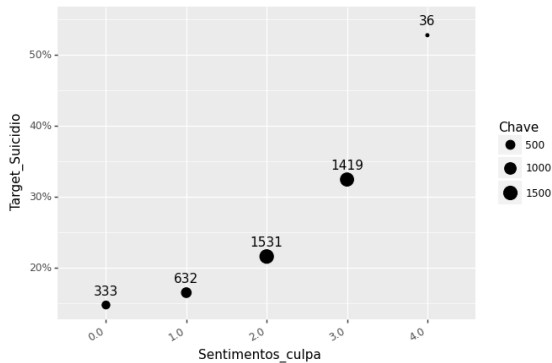


Figure – Sentimentos de culpa

Dataset

Target : Suicídio




Figure – Trabalho e interesses

Dataset

Target : Suicídio

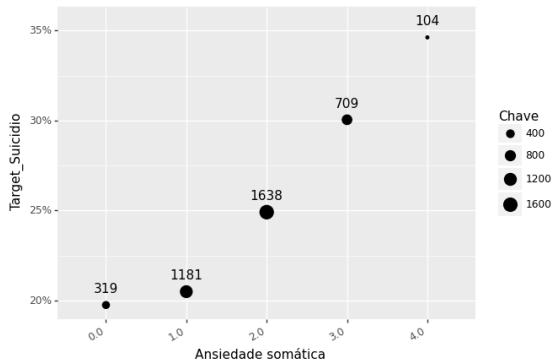


Figure – Ansiedade somática

Dataset

Target : Suicídio




Figure – Sexo

Dataset

Heatmaps




Figure – Variáveis Pessoais

Dataset

Heatmaps




Figure – Variáveis emocionais

Dataset

Heatmaps




Figure – Variáveis Físicas

IRT

Transformação do target

- O target para a geração do grafo é contínuo
- Nossas variáveis são categóricas
- Aplicação de IRT
- Referência : Constructing interval variables via faceted Rasch measurement and multitask deep learning : a hate speech application (Kennedy et al., 2020)

IRT

Transformação do target

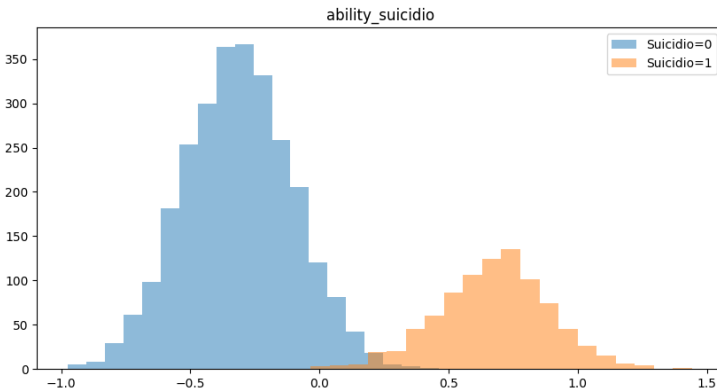


Figure – Distribuição dos resultados após aplicar IRT sobre as variáveis de suicídio e ansiedade

Modelo causal gráfico

CausalNex

- Apesar de observarmos relações positivas entre o target ‘Suicídio’ e algumas variáveis preditoras usando apenas análise de correlação, não podemos afirmar que ‘Suicídio’ seria uma consequência dessas variáveis.
- A capacidade de identificar relações verdadeiramente causais é fundamental para efetuar intervenções que possam impactam positivamente a vida das pessoas.
- A presença de variáveis de confusão que influenciam tanto o target quanto um direcionador desse target são ameaças graves ao fazer inferência causal em dados observacionais.
- Determinar a causalidade entre variáveis pode ser um passo desafiador. Para tanto iniciamos o processo gerando o grafo acíclico dirigido (DAG) objetivando efetuar uma seleção de features identificadas como possíveis causas do nosso target.

Modelo causal gráfico

CausalNex

Para obter as *features* identificadas como possíveis causas do nosso *target* seguimos as seguintes etapas :

- Geração do grafo causal : para os *targets* 'Suicídio' e 'Ansiedade' objetivando capturar a individualidade.
- Remoção de arestas com baixa estimativa de probabilidade (peso menor que 0,5).
- Remoção das arestas que não fazem parte do *Markov Blanket* (incluindo os pais do nosso *target*, filhos e os pais de todos os seus filhos).
- Revisão da estrutura. Cada relação deve ser validada, para que possa ser afirmada como causal. Isso pode envolver inverter, remover ou adicionar arestas aprendidas ou confirmar o conhecimento especializado com especialistas da área.

Modelo causal gráfico

CausalNex

- Utilizamos a biblioteca *Python CausalNex* que permite desenvolver modelos considerando relações causais.
- Inicialmente geramos o grafo acíclico dirigido (*DAGs*) que descreve as dependências condicionais entre as variáveis utilizando o algoritmo *notears*.
- *Notears* funciona detectando se um pequeno aumento no valor do nó resultará em um aumento em outro nó. Se houver, ela será capaz de capturar isso e afirmar que esta é uma relação causal. Portanto, é recomendável que o conjunto de dados seja contínuo. Por esse motivo, normalizamos nossas *features*.
- É recomendado que pelo menos 1000 amostras sejam usadas para obter um desempenho satisfatório e como nosso *Dataset* tem mais de 3600 amostras, foi possível utilizá-lo.

Modelo causal gráfico

CausalNex

- Para imprimir o grafo utilizamos o algoritmo *plot structure* da mesma biblioteca, removendo as arestas cujos pesos absolutos eram menores que 0.5.
- Para a geração do grafo foram utilizadas as seguintes *features* : Sexo, Estado Civil, Tipo de Residência, Alcoólatra, Droga, Suicídio na Família, Depressão na Família, Alcoólatra Família, Droga na Família, Neuro, Psiquiátrica, Capaz de desfrutar das coisas, Impacto de sua Família e amigos, Capaz de tomar decisões importantes, Estudante, Insônia, Ansiedade, Perda de *insights*, Appetite, Perda de Peso, Ansiedade somática, Hipocondriase, Sentimento de Culpa, Trabalho e interesses, Energia, Lentidão pensamento e fala, Agitação, Libido, TOC, idade e Suicídio após aplicação descrita no item 4.2.

CausalNex

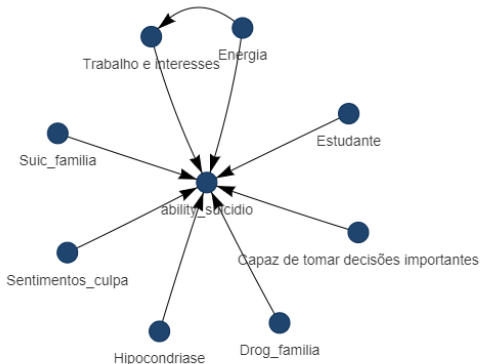
Grafo gerado com todas as *features* removendo arestas cujos pesos absolutos eram menores que 0.5



Modelo causal gráfico - Target Suicídio

CausalNex


Grafo gerado removendo as arestas que não fazem parte do **Markov Blanket** (incluindo os pais do nosso target, filhos e os pais de todos os seus filhos)



Modelo causal gráfico - Target Suicídio

CausalNex

Features com estimativa de probabilidades.



Modelo causal gráfico - Target Suicídio

CausalNex

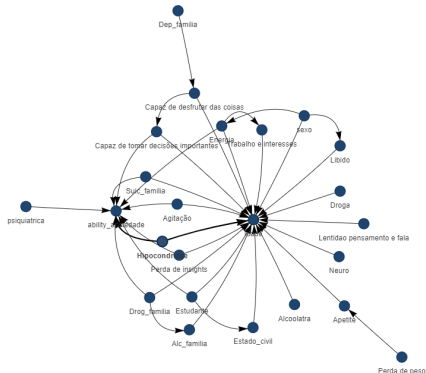
Esse grafo foi validado pelo psicólogo André Santos Araujo (CRP08 - 23885) que trata principalmente pacientes com transtornos psicológicos bem como pacientes com ideação suicida.



Figure – andrecogito.com.br

CausalNex

Grafo gerado com todas as *features* removendo arestas cujos pesos absolutos eram menores que 0.5




CausalNex


Grafo gerado removendo as arestas que não fazem parte do **Markov Blanket** (incluindo os pais do nosso target, filhos e os pais de todos os seus filhos)



Counterfactual



(a) Counterfactual network model training.



(b) Counterfactual model prediction.

Contrafactual

Modifications: Sentimentos_culpa from 4 to 0

	Suicidio	New_Suicidio	Ansiedade	New_Ansiedade
2253	3	0	1	0
2787	1	0	1	1
2449	2	0	0	0
1724	2	1	3	2
2596	2	0	3	2
653	1	1	3	3
2801	3	0	1	1
54	0	0	2	1
2093	2	0	2	2
1444	2	1	2	1

Baseline

Modelo de classificação - *target* 'Suicídio' - Redes neurais com 8 e 32 *features*




Figure – Evolução *loss* - Treino

Baseline

Modelo de classificação - *target* 'Suicídio' - Redes neurais com 8 e 32 *features*




Figure – Evolução *loss* - Validação

Baseline

Modelo de classificação - *target* 'Suicídio' - Redes neurais com 8 e 32 *features*

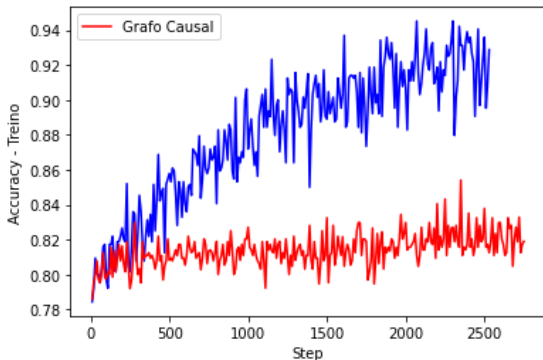


Figure – Evolução *Accuracy* - Treino

Baseline

Modelo de classificação - *target* 'Suicídio' - Redes neurais com 8 e 32 *features*


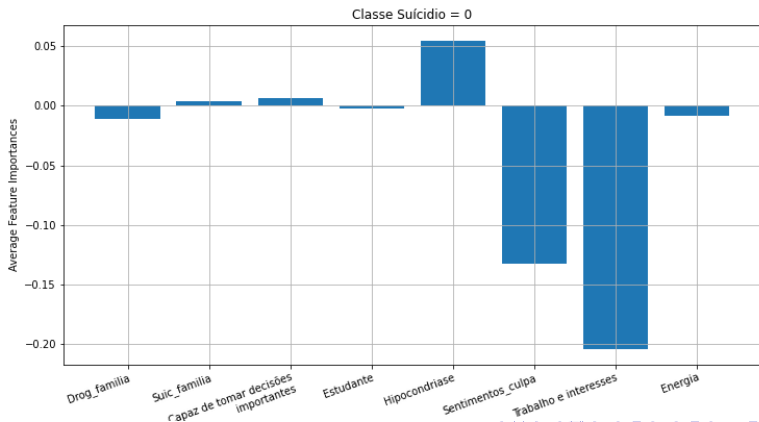


Figure – Evolução *Accuracy* - Validação

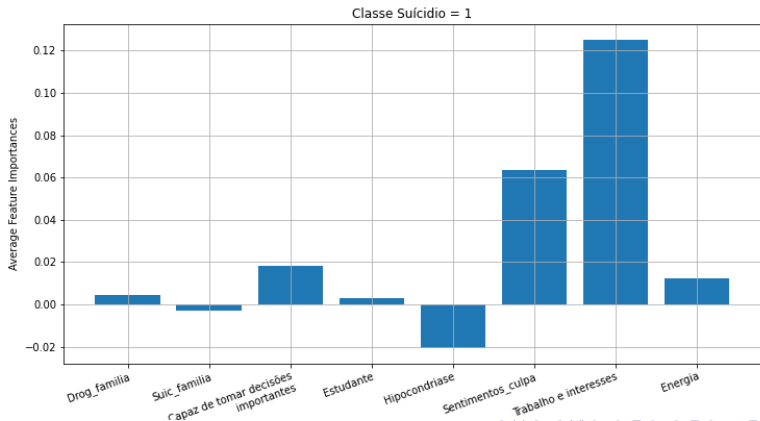
Explicabilidade

SHAP Values - COM causalidade - *Target* Suicídio - Categoria 0




Explicabilidade

SHAP Values - COM causalidade - *Target* Suicídio - Categoria 1



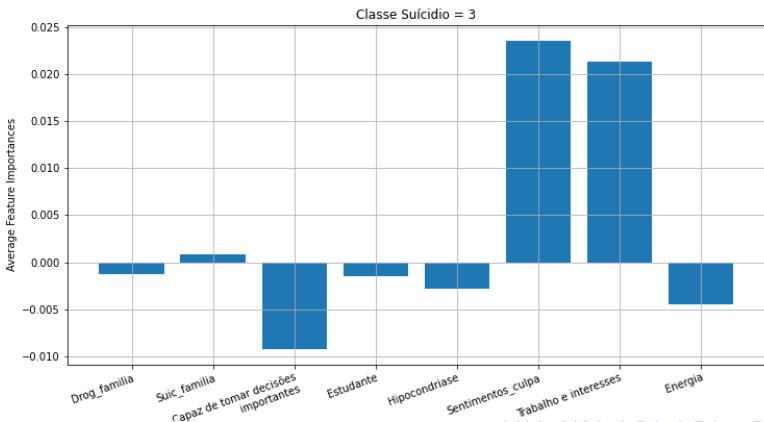
Explicabilidade

SHAP Values - COM causalidade - *Target* Suicídio - Categoria 2



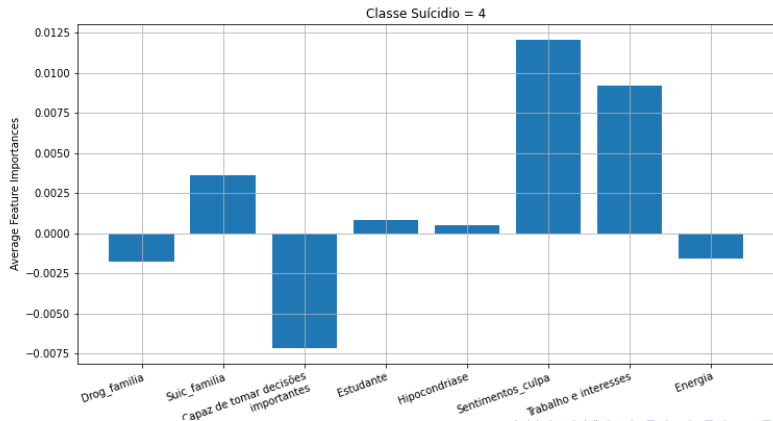
Explicabilidade

SHAP Values - COM causalidade - *Target* Suicídio - Categoria 3




Explicabilidade

SHAP Values - COM causalidade - *Target* Suicídio - Categoria 4




Explicabilidade

SHAP Values - SEM causalidade - *Target* Suicídio - Categoria 0



Explicabilidade

SHAP Values - SEM causalidade - *Target* Suicídio - Categoria 4



Explicabilidade

Grafo causal

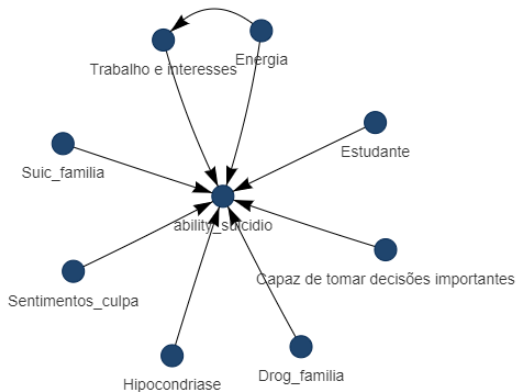


Figure – Grafo Causal com Markov Blanket

Conclusões

Importante incorporar **causalidade em aprendizagem de máquina** em vários contextos, principalmente em questões da área de **saúde**

Obrigada(o)!

